

Curso Um

Fundamentos da Ciência de Dados



Instruções

Utilize este documento de estratégia PACE para registrar decisões e reflexões ao longo do desenvolvimento deste projeto final de curso. Você pode usar este documento como um guia para analisar suas respostas e reflexões em diferentes etapas do processo de análise de dados. Além disso, os documentos de estratégia PACE podem servir como recurso em projetos futuros.

Resumo do Projeto do Curso

Independentemente do caminho que você escolheu seguir, seus objetivos para este projeto são:

- ☐ Responda às perguntas no documento de estratégia PACE do Curso 1.
- ☐ Responda às perguntas no arquivo do projeto Jupyter Notebook.
- ☐ Conclua o trabalho preparatório de codificação no notebook Jupyter do projeto.
- ☐ Resuma a coluna Dtypes
- ☐ Comunique as principais conclusões na forma de um resumo executivo.


Perguntas relevantes para entrevistas

Concluir o projeto final do curso ajudará você a responder a esses tipos de perguntas que costumam ser feitas durante o processo de entrevista:

- Descreva os passos que você seguiria para limpar e transformar um conjunto de dados não estruturados.
- Que aspectos específicos você procuraria durante o processo de limpeza?
- Quais são alguns dos valores discrepantes, anomalias ou aspectos incomuns que você pode procurar no processo de limpeza de dados e que podem impactar as análises ou a capacidade de gerar insights?

Guia de Referência

Este projeto possui três tarefas; a imagem abaixo identifica como as etapas do PACE são incorporadas nessas tarefas.



Perguntas e considerações sobre o projeto de dados



PACE: Fase de Planejamento

- Como você pode se preparar da melhor forma para entender e organizar as informações fornecidas?

Definindo o objetivo de negócio (auxiliar o TikTok a classificar vídeos entre alegações e opiniões para otimizar a moderação);

Carregar as bibliotecas essenciais: numpy e pandas;

Planejar a inspeção estrutural das variáveis.

- Que manuais de código para acompanhamento e autoavaliação irão ajudá-lo a realizar este trabalho?

Exemplos práticos já trabalhados nas aulas para inspecionar tipos de dados (dtypes) e estruturas de dados;

Documentação oficial do python e pandas;

Guias de referências do pandas e numpy.

- Quais são algumas atividades adicionais que um aluno proativo realizaria antes de começar a programar?

Revisar o dicionário de dados e a proposta do projeto;



Mapear como o resultado da análise atende às necessidades dos gestores e da equipe;
Questionar previamente o que se espera encontrar, por exemplo, antecipar se vídeos que fazem alegações tendem a ter maior alcance ou maior taxa de denúncias/banimentos.



PACE: Analisar a fase

- Com base na sua intuição e na análise das variáveis, as informações disponíveis serão suficientes para atingir o objetivo?

Sim, os dados são suficientes para este estágio exploratório inicial, pois contêm variáveis-chave de engajamento, o status de reivindicação, o status da conta do autor e as transcrições em texto.

- Como você construiria um dataframe com estatísticas resumidas e avaliaria os valores mínimo e máximo da amplitude dos dados?

Utilizando o método `data.describe()` do Pandas para gerar automaticamente. Além disso, agrupando as variáveis por categoria com `data.groupby('claim_status').agg(['min', 'max', 'mean', 'median'])` para comparar as amplitudes entre reivindicações e opiniões.

- Alguma das médias das variáveis de dados parece incomum? Você consegue descrever os dados intervalares?

parecem inflacionadas quando comparadas às medianas globais devido à extrema disparidade entre as duas classes. No entanto, dentro de cada classe (claim e opinion), as médias e medianas são praticamente iguais, indicando distribuições aproximadamente simétricas e uniformes



PACE: Etapa de Construção

Observação: A etapa de Construção não se aplica a este fluxo de trabalho. A estrutura PACE pode ser adaptada para atender aos requisitos específicos de qualquer projeto.



PACE: Executar Etapa

- Considerando seu conhecimento atual dos dados, o que você recomendaria inicialmente ao seu gerente para investigar mais a fundo antes de realizar uma análise exploratória de dados?

verificar o padrão dos valores ausentes, avaliar a consistência das transcrições de texto e aprofundar a relação entre o banimento de autores e vídeos de reivindicação, garantindo que o conjunto de dados esteja devidamente limpo e balanceado.

- Que dados se apresentam inicialmente como contendo anomalias?

quase não existem vídeos de opinion com alto engajamento, nem vídeos de claim com alcance muito baixo. Além disso, as linhas que contêm valores nulos em variáveis de engajamento também carecem de transcrição e status de alegação, se comportando como registros incompletos.

- Que tipos adicionais de dados poderiam fortalecer este conjunto de dados?

métricas temporais, como data e horário de publicação, tempo em que o vídeo permaneceu no ar, histórico anterior de infrações do autor e informações sobre denúncias ativas feitas pelos usuários.