

Curso Dois

Vá além dos números: transforme dados em insights.



Instruções

Utilize este documento de estratégia PACE para registrar decisões e reflexões ao longo do desenvolvimento deste projeto final de curso. Você pode usar este documento como um guia para analisar suas respostas e reflexões em diferentes etapas do processo de análise de dados. Além disso, os documentos de estratégia PACE podem servir como recurso em projetos futuros.

Resumo do Projeto do Curso

Independentemente do caminho que você escolheu seguir, seus objetivos para este projeto são:

- ☐ Responda às perguntas no documento de estratégia PACE do Curso 2.
- ☐ Responda às perguntas no arquivo do projeto Jupyter Notebook.
- ☐ Limpe seus dados e realize uma análise exploratória de dados (EDA).
- ☐ Criar visualizações de dados
- ☐ Crie um resumo executivo para compartilhar seus resultados.

Perguntas relevantes para entrevistas


Concluir o projeto final do curso ajudará você a responder a esses tipos de perguntas que costumam ser feitas durante o processo de entrevista:

- Como você explicaria a diferença entre fontes de dados qualitativos e quantitativos?
- Descreva a diferença entre dados estruturados e não estruturados.
- Por que é importante realizar análises exploratórias de dados?
- Como você realizaria uma Análise Exploratória de Dados (EDA) em um determinado conjunto de dados?
- Como criar ou alterar uma visualização com base em diferentes públicos?
- Como evitar vieses e garantir a acessibilidade em uma visualização de dados?

- Como a visualização de dados influencia sua análise exploratória de dados (EDA)?

Guia de Referência

Este projeto possui seis tarefas; a imagem abaixo identifica como as etapas do PACE são incorporadas nessas tarefas.



Perguntas e considerações sobre o projeto de dados



PACE: Fase de Planejamento

- Quais são as colunas de dados e variáveis, e quais delas são mais relevantes para o seu produto final?

As variáveis: claim_status, video_id, video_duration_sec, video_transcription_text, verified_status, author_ban_status, video_view_count, video_like_count, video_share_count, video_comment_count, video_download_count.

Mais relevantes para o produto final: claim_status (target), video_view_count, video_like_count, author_ban_status e verified_status pois são as que demonstram maior poder discriminante na EDA.

- Em que unidades estão suas variáveis?

As variáveis numéricas estão expressas em unidades de tempo (segundos) ou contagem de eventos, enquanto as variáveis do tipo texto representam categorias ou descrições



- Quais são suas suposições iniciais sobre os dados que podem fundamentar sua Análise Exploratória de Dados (AED), sabendo que você precisará confirmá-las ou refutá-las com suas descobertas futuras?

A duração do vídeo tem distribuição aproximadamente uniforme ;
Usuários verificados postam proporcionalmente mais opiniões ;
Vídeos classificados como *claim* têm mais engajamento que *opinion*;

- Há dados em falta ou incompletos?

O dataset tem 19.382 linhas, mas algumas colunas têm 19.084 valores não nulos, ou seja, 298 registros com dados faltantes.

- Todas as partes deste conjunto de dados estão no mesmo formato?

O dataset é um único arquivo CSV onde cada linha é um vídeo, cada coluna é uma variável.

- Quais práticas de EDA serão utilizadas?obrigatório para iniciar este projeto?

inspeção da estrutura dos dados: aplicando funções como `head()`, `info()`, `describe()`, `size`, `shape`.
limpeza: verificação e remoção de nulos.
visualização: criação de histogramas para examinar os padrões de distribuição, construção de boxplots direcionados à identificação de discrepâncias (outliers).



PACE: Analisar a fase

- Quais são os passos necessários para realizar a EDA da forma mais eficaz possível para atingir o objetivo do projeto?

Mapear e efetuar o tratamento de dados ausentes;

Obter as métricas de sumarização e métricas estatísticas essenciais;

Construir gráficos individuais, histogramas e boxplots para examinar o comportamento das variáveis;

Elaborar representações gráficas comparativas, barplot e scatterplot avaliando o relacionamento entre múltiplos atributos;

Mensurar pontos discrepantes através do intervalo interquartil (IQR);

Sintetizar as descobertas obtidas e estruturar as conclusões estratégicas.

- Você precisa adicionar mais dados usando a prática de EDA de junção? Que tipo de estruturação precisa ser feita neste conjunto de dados, como filtragem, ordenação, etc.?

Não é necessário juntar dados externos. O dataset é autocontido.

- Quais são suas suposições iniciais sobre os tipos de visualizações mais adequados para o público-alvo?

Análise da dispersão de dados: Histograma

Mapeamento de outliers: Boxplot

Avaliação comparativa dos grupos categóricos: Barplot

Exame da associação entre variáveis: Scatterplot

Distribuição proporcional dos dados agregados: Pie chart



PACE: Etapa de Construção

- Que visualizações de dados, algoritmos de aprendizado de máquina ou outras saídas de dados precisarão ser criadas para atingir os objetivos do projeto?

Visualizações (Python): histogramas, boxplots.

Visualizações (Tableau): dashboard com claims vs. opinions e stacked bar charts para views, likes, shares e downloads.

Modelo preditivo: classificação binária (claim vs. opinion).

- Quais processos precisam ser realizados para construir as visualizações de dados necessárias?

import das libs necessárias;

Configurar figsize para legibilidade;

Aplicar títulos, rótulos de eixo e legendas;

Usar paletas de alto contraste.

- Quais variáveis são mais adequadas para as visualizações neste projeto de dados?

claim_status, video_like_count, video_download_count, video_share_count, video_comment_count, author_ban_status, verified_status

- Voltando à fase de Planejamento, como você pretende lidar com os dados faltantes (se houver)?

Documentar a decisão no notebook para rastreabilidade.



PACE: Executar Etapa

- Quais foram as principais conclusões que surgiram da sua análise exploratória de dados (EDA) e das visualizações?

Claims aparecem mais nas visualizações, mediana de 501.555 views para claim vs. 4.953 para opinion.

Autores banidos/sob revisão têm mais views.

Usuários verificados são minoria, mas mais propensos a postar opiniões.

Distribuições assimétricas à direita, onde a maioria dos vídeos tem < 100 mil views/curtidas.

Vídeos distribuídos quase igualmente entre 0 e 60 s.

Outliers presentes em todas as contagens 2.343 em views, 3.468 em likes, 3.732 em shares, 3.733 em downloads, 3.882 em comentários.

- Que recomendações de negócios e/ou organizacionais você propõe com base na(s) visualização(ões) criada(s)?

Priorizar video_view_count como feature principal no modelo.

Incluir author_ban_status como variável relevante.

Tratar outliers com cautela, mantê-los se representarem virais reais; removê-los apenas se forem erros de coleta.

Criar dashboards

- Considerando o que você sabe sobre os dados e as visualizações que estavam sendo usadas, que outras perguntas você poderia pesquisar para a equipe?

A duração do vídeo influencia a probabilidade de ser claim ou opinion?

O texto da transcrição pode ser usado como feature de NLP para classificação?

Como o status de verificação interage com o tipo de conteúdo ao longo do tempo?



- Como você poderia compartilhar essas visualizações com diferentes públicos?

Equipe: Notebook python;

Stakeholders: Dashboard Tableau/Power Bi

Liderança: Sumário Executivo PPTX