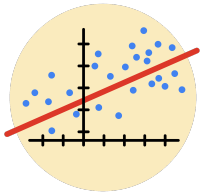
Curso Quatro

Análise de regressão: simplificando relações complexas de dados



Instruções

Utilize este documento de estratégia PACE para registrar decisões e reflexões à medida que você desenvolve este projeto de final de curso. Lembre-se de que este documento é um recurso que você poderá consultar no futuro e um guia para ajudá-lo a considerar respostas e reflexões apresentadas em vários momentos ao longo do projeto.

Resumo do Projeto do Curso

Independentemente do caminho que você escolheu seguir, seus objetivos para este projeto são:

- ☑ ~~Responda às perguntas no documento de estratégia PACE do Curso 4.~~
- ☑ ~~Responda às perguntas no arquivo do projeto Jupyter Notebook.~~
- ☑ ~~Construa um modelo de regressão linear múltipla~~
- ☑ ~~Avalie o modelo~~
- ☑ ~~Elabore um resumo executivo para os membros da equipe.~~

Perguntas relevantes para entrevistas

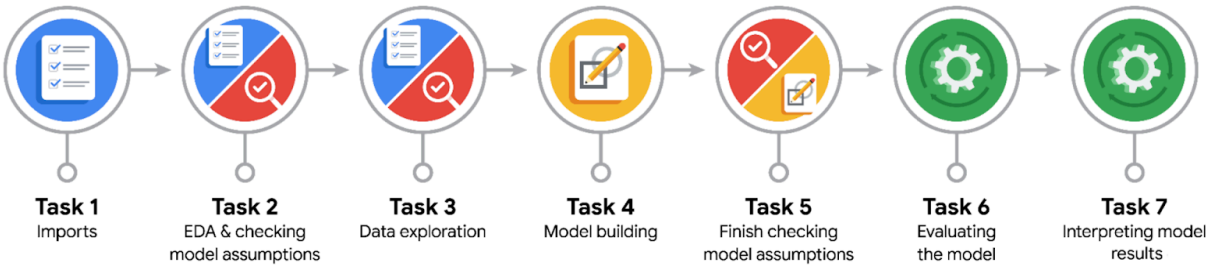
A conclusão do projeto final do curso lhe dará as ferramentas necessárias para responder aos seguintes tópicos de entrevista:

- Descreva os passos que você seguiria para realizar uma análise baseada em regressão.
- Liste e descreva os aspectos críticos.pressupostos da regressão linear
- Qual é a principal diferença entre R^2 e R^2 ajustado?
- Como interpretar um gráfico Q-Q em um modelo de regressão linear?

- O que é a relação entre viés e variância? Como ela se relaciona com a construção de um modelo de regressão linear múltipla? Considere a seleção de variáveis e o R^2 ajustado.

Guia de Referência

Este projeto possui sete tarefas; a imagem abaixo identifica como as etapas do PACE são incorporadas nessas tarefas.



Perguntas e considerações sobre o projeto de dados

PACE: Fase de Planejamento

- Quem são as partes interessadas externas para este projeto?

Os usuários do TikTok que enviam relatórios e denúncias identificando vídeos e comentários, bem como os criadores de conteúdo da plataforma cujos vídeos passam pelo processo de triagem e moderação

- O que você está tentando resolver ou realizar?

Desenvolver um modelo de regressão para os dados de classificação de sinistros.

- Quais são suas observações iniciais ao explorar os dados?

Há um equilíbrio quase perfeito entre vídeos de opinião e afirmação no conjunto de dados (aproximadamente 9.608 afirmações e 9.476 opiniões).

As variáveis de engajamento (video_view_count, video_like_count, video_share_count, video_download_count) apresentam média/mediana significativamente maiores em vídeos de afirmação em comparação aos vídeos de opinião.

Contas não verificadas estão fortemente associadas a uma maior quantidade de visualizações e maior proporção de vídeos classificados como afirmação.

- Quais recursos você costuma usar para concluir esta etapa?

Documentação do Scikit-Learn (LogisticRegression, train_test_split), guias de pré-processamento para One-Hot Encoding e documentação das bibliotecas seaborn e matplotlib para visualizações.



PACE: Analisar a fase

- Quais são alguns dos objetivos da Análise Exploratória de Dados (EDA) antes da construção de um modelo de regressão linear múltipla?

Avaliar e tratar valores ausentes (null values) em colunas de engajamento e status de verificação.

Analisar a multicolinearidade entre variáveis preditoras (como contagem de curtidas, visualizações e compartilhamentos).

Verificar a distribuição das variáveis numéricas e converter variáveis categóricas (como verified_status e author_ban_status) em variáveis dummy.

- Você tem alguma consideração ética nesta fase?

Sim. É fundamental garantir a privacidade e o uso responsável dos dados dos usuários. Nenhuma informação de identificação pessoal (PII) é utilizada. O modelo foca estritamente em métricas agregadas de engajamento, duração do vídeo e dados de status de verificação/banimento para evitar vieses injustos na moderação e na classificação de usuários.



PACE: Etapa de Construção

- Você percebe algo estranho?

As variáveis de engajamento possuem alta colinearidade entre si (vídeos com muitas visualizações também acumulam muitas curtidas e compartilhamentos), o que exige cuidado na seleção de recursos do modelo de regressão logística.

Há um desequilíbrio considerável na classe alvo original de status de verificação (aproximadamente 94% não verificados vs. 6% verificados), exigindo técnicas de reamostragem (upsampling) da classe minoritária para equilibrar o treinamento do modelo.

As magnitudes dos coeficientes da regressão logística resultaram muito pequenas, indicando que nenhuma variável isolada tem um impacto desproporcional na previsão, mas sim o conjunto de métricas combinadas.

- Você pode melhorá-lo? Há algo que você mudaria no modelo?

Sim:

- Engenharia de atributos: criar métricas relativas ou proporções (ex.: razão entre curtidas e visualizações, ou compartilhamentos por visualizações) para reduzir o efeito da colinearidade entre contagens absolutas.
- Extrair recursos adicionais de texto a partir do video_transcription_text utilizando técnicas de PNL (como TF-IDF ou embeddings) para enriquecer o conjunto de preditores.
- Sim, codificar adequadamente as variáveis categóricas, selecionar as variáveis preditoras mais relevantes para evitar multicolinearidade e avaliar a viabilidade de modelos não paramétricos baseados em árvores (como Random Forest ou XGBoost) em etapas futuras.

- Quais recursos você costuma usar para concluir esta etapa?

Classes e funções LogisticRegression(), OneHotEncoder(), classification_report(), confusion_matrix() e ConfusionMatrixDisplay do Scikit-Learn.



PACE: Executar Etapa

- Quais foram as principais conclusões que surgiram do(s) seu(s) modelo(s)?

Desempenho Geral e Acurácia: O modelo de regressão logística alcançou ~54% de acurácia no conjunto reamostrado (8.942 observações). Com 3.946 verdadeiros negativos e 847 verdadeiros positivos, demonstra capacidade moderada em classificar o status de verificação pelos atributos do vídeo.

Análise dos Coeficientes: As variáveis video_comment_count (β ≈ 3,89e-04), video_duration_sec (β ≈ 1,38e-04), claim_status_opinion (β ≈ 6,10e-06) e video_share_count (β ≈ 6,18e-06) tiveram relação positiva com a verificação. Já video_download_count (β ≈ -1,99e-04), video_view_count (β ≈ -1,67e-06) e video_like_count (β ≈ -8,93e-07) apresentaram coeficientes negativos. Por serem baixos em magnitude, nenhum atributo isolado domina a predição.

Estratégia de Reamostragem: O upsampling foi essencial para equilibrar os dados no treino, permitindo avaliar F1-score, precisão e recall no teste.

- Que recomendações de negócios você propõe com base nos modelos construídos?

Usar as relações identificadas entre engajamento e contas verificadas como um sinal secundário para otimizar as filas de moderação de conteúdo, combinando a previsão de verificação com a classificação entre afirmações (claims) e opiniões para priorizar denúncias de alto impacto.

- Para interpretar os resultados do modelo, por que é importante interpretar os coeficientes beta?

A interpretação dos coeficientes beta (β) na regressão logística é essencial, pois eles quantificam a variação no logaritmo da razão de chances (log-odds) de uma conta ser verificada a cada incremento unitário em um preditor, mantendo as demais variáveis constantes. Essa análise expõe o sentido do impacto de cada métrica:

• **Valores positivos** (como na duração do vídeo, video_duration_sec, e no volume de comentários) indicam uma correlação em que métricas mais altas elevam as chances de verificação.

• **Valores negativos** (observados em visualizações e downloads) mostram que aumentos nessas variáveis estão ligados a uma menor probabilidade relativa do perfil ser verificado no modelo ajustado.

- Que recomendações você faria?

Integrar o modelo às análises da equipe de produto e operações para entender como perfis verificados se comportam em comparação com contas não verificadas ao postar afirmações ou opiniões.

Combinar as previsões de status de verificação com a classificação de vídeos (claim vs. opinion) para otimizar as filas de moderação prioritária de conteúdo.

- Você acha que seu modelo poderia ser melhorado? Por quê? Como?

Sim, o modelo pode ser aperfeiçoado. A forte multicolinearidade entre as métricas de engajamento (como visualizações e curtidas, com r > 0,85) e a incapacidade da regressão logística em modelar interações não lineares complexas sugerem as seguintes melhorias: 1) Engenharia de atributos voltada para razões de engajamento; 2) Aplicação de PNL e TF-IDF para extrair recursos do texto de transcrição (video_transcription_text);

- Com base nos modelos construídos, que recomendações de negócios/organizacionais você proporia?

Utilizar o modelo como um indicador complementar na triagem automatizada de denúncias de usuários.

Reavaliar periodicamente os limites de decisão do modelo e a reamostragem das classes conforme novos dados de engajamento sejam coletados.

- Considerando o seu conhecimento sobre os dados e os modelos que vocês estavam utilizando, que outras perguntas você poderia abordar para a equipe?

Como a inclusão do conteúdo do texto da transcrição (via sentiment analysis ou N-grams) impactaria a precisão da classificação?

Existe alguma diferença de comportamento significativa entre contas banidas vs. sob revisão ao postar alegações (claims)?

- Você tem alguma consideração ética nesta fase?

Com certeza. O modelo precisa atuar unicamente como uma ferramenta de auxílio à decisão em etapas de triagem, sendo vedada a aplicação automática de penalidades aos usuários. É imprescindível assegurar a imparcialidade na moderação e na visibilidade para criadores sem verificação, preservando a transparência das decisões, o acompanhamento humano constante e a disponibilidade de mecanismos acessíveis para recurso.