TikTok Claims Classification Project

Machine Learning Model - Executive Summary

Overview

A equipe de dados do TikTok busca desenvolver modelos de Random Forest e XGBoost para classificar automaticamente vídeos como afirmação (claim) ou opinião (opinião), utilizando características dos vídeos e métricas de engajamento para prever a variável claim_status.

Objective

Construir um modelo de machine learning para prever a variável **claim_status** (*claim* ou *opinion*) com base em características dos vídeos e métricas de engajamento, auxiliando a equipe do TikTok a identificar e priorizar conteúdos para análise.

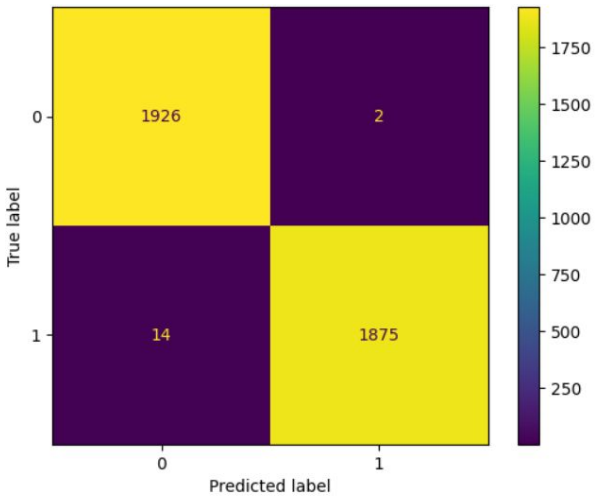
Results

Modelos de **Random Forest (RF)** e **XGBoost** foram avaliados para classificar vídeos como claim ou opinion, ambos alcançaram um ótimo resultado de precisão, recall e acurácia.

O **RF** foi selecionado como o modelo final por apresentar resultados ligeiramente melhores, obteve uma pontuação de *recalll* melhor (0,991). As métricas de engajamento (visualizações, curtidas e compartilhamentos) foram as variáveis mais importantes. Com apenas 16 amostras classificadas erroneamente o modelo final demonstrou alta capacidade de generalização.

Com base nesses resultados, conclui-se que os vídeos com maior engajamento de usuários apresentavam uma probabilidade significativamente maior de receber reivindicações ou contestações.

A matriz de confusão do Random Forest



Nos dados de validação, apenas 16 das 3.817 amostras foram classificadas incorretamente.

Next Steps

Incorporar novas variáveis comportamentais dos usuários e características do conteúdo dos vídeos, além de realizar testes adicionais de otimização e monitorar o desempenho com novos conjuntos de dados. É fundamental acompanhar periodicamente as métricas de engajamento com destaque para visualizações, curtidas e compartilhamentos, visto que esses fatores se mostraram os mais determinantes para os resultados do modelo.