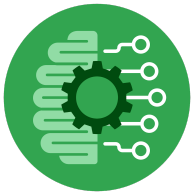
Curso Cinco

Os fundamentos do aprendizado de máquina



Instruções

Utilize este documento de estratégia PACE para registrar decisões e reflexões à medida que desenvolve o projeto final do curso. Lembre-se de que este documento é um recurso que você poderá consultar no futuro e um guia para ajudá-lo a considerar respostas e reflexões apresentadas em vários momentos ao longo do projeto.

Resumo do Projeto do Curso

Independentemente do caminho que você escolheu seguir, seus objetivos para este projeto são:

- ☑ ~~Responda às perguntas no documento de estratégia PACE do Curso 5.~~
- ☑ ~~Responda às perguntas no arquivo do projeto Jupyter Notebook.~~
- ☑ ~~Construa um modelo de aprendizado de máquina~~
- ☑ ~~Elabore um resumo executivo para os membros da equipe e demais partes interessadas.~~

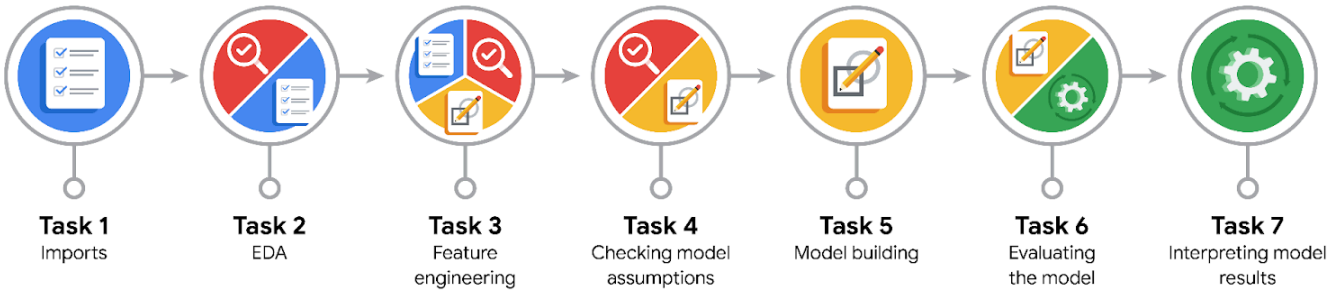
Perguntas relevantes para entrevistas

A conclusão do projeto final do curso lhe dará as ferramentas necessárias para responder aos seguintes tópicos de entrevista:

- Que tipos de problemas empresariais seriam melhor resolvidos por modelos de aprendizagem supervisionada?
- Quais são os requisitos necessários para criar modelos eficazes de aprendizado supervisionado?
- O que significa aprendizado de máquina para você?
- Como você explicaria o funcionamento dos algoritmos de aprendizado de máquina para um colega de equipe que não está familiarizado com o conceito?
- Como funciona o gradient boosting?

Guia de referência:

Este projeto possui sete tarefas; a imagem abaixo identifica como as etapas do PACE são incorporadas nessas tarefas.



Perguntas e considerações sobre o projeto de dados

PACE: Fase de Planejamento

- O que você está tentando resolver ou realizar?

Construir um modelo de ML capaz de classificar vídeos como reivindicações (claims) ou opiniões (opinions), utilizando as variáveis do conjunto de dados para apoiar decisões relacionadas à moderação de conteúdo.

- Quem são os stakeholders externos que apresentarei para este projeto?

Usuários da plataforma TikTok, criadores de conteúdo, anunciantes e parceiros que podem ser impactados pelas decisões de moderação e classificação de vídeos.

- Quais recursos você costuma usar para concluir esta etapa?

Linguagem Python e bibliotecas de análise de dados (Pandas, NumPy, Matplotlib, Seaborn, Scikit-learn, Statsmodels), cadernos Jupyter e a documentação interna da estrutura PACE do projeto.

- Você tem alguma consideração ética nesta fase?

  É fundamental considerar os impactos dos erros de classificação, especialmente falsos positivos e falsos negativos, que podem afetar a moderação de conteúdo e a experiência dos usuários.

- Meus dados são confiáveis?

  Os dados são razoavelmente confiáveis para exploração, mas contêm valores ausentes (298 linhas nulas em diversas colunas) e desbalanceamento acentuado de classes (~94% não verificados vs ~6% verificados), exigindo tratamento prévio antes da modelagem.

- Em um mundo ideal, de que dados eu precisaria/gostaria de ver para responder a esta pergunta?

  Seria ideal ter dados de histórico de denúncias detalhados, dados de engajamento temporal mais refinados, taxa de retenção de público e métricas mais completas sobre o comportamento dos criadores de conteúdo.

- Que dados eu tenho/posso obter?

  Dispomos do conjunto de dados `tiktok_dataset.csv` contendo 19.382 linhas com atributos como `video_duration_sec`, `video_view_count`, `video_like_count`, `video_share_count`, `video_download_count`, `video_comment_count`, `claim_status`, `verified_status` e `author_ban_status`.

- Que métrica devo usar para avaliar o sucesso do meu objetivo empresarial/organizacional? Por quê?

  Recall é uma métrica importante porque deixar passar um vídeo que realmente contém uma reivindicação pode ter consequências maiores do que sinalizar incorretamente um vídeo como reivindicação. No entanto, a decisão final deve considerar o impacto relativo dos falsos positivos e dos falsos negativos para o negócio.



PACE: Analisar a fase

- Reavalie a questão: "O que estou tentando resolver?". Ainda funciona? O plano precisa ser revisado?

Sim. O objetivo continua sendo classificar vídeos como claim ou opinion. O plano não precisou de alterações significativas, apenas etapas de tratamento e preparação dos dados.

- Os dados contradizem as premissas do modelo? Isso é aceitável ou inaceitável?

Não. Embora existam valores ausentes e desbalanceamento em algumas variáveis, os dados foram tratados adequadamente e são compatíveis com os modelos utilizados.

- Por que você selecionou as variáveis X que selecionou?

As variáveis foram escolhidas por representarem características dos vídeos e métricas de engajamento que podem influenciar a classificação entre claim e opinion.

- Quais são alguns dos objetivos da EDA (Análise Exploratória de Dados) antes da construção de um modelo?

Compreender a distribuição das variáveis, identificar e tratar valores ausentes ou discrepantes (outliers), verificar a correlação/multicolinearidade entre recursos preditores e examinar o equilíbrio das classes da variável alvo.

- O que a EDA lhe disse?

A EDA mostrou que apenas ~6% das contas eram verificadas no conjunto original, que havia 298 valores ausentes em diversas colunas e que variáveis de engajamento (como curtidas, visualizações e compartilhamentos) têm forte correlação entre si e distribuições altamente assimétricas à direita.

- Quais recursos você costuma usar para concluir esta etapa?

Módulos do Python como Pandas (funções `.info()`, `.describe()`, `.isna()`), Seaborn/Matplotlib para visualizações (boxplots, histogramas e mapas de calor de correlação) e Scikit-learn para reamostragem.



PACE: Etapa de Construção

- Percebo algo estranho? É um problema? Tem solução? Se sim, como?

Foram identificados valores ausentes e distribuições assimétricas. Esses problemas foram tratados durante o pré-processamento dos dados.

- Quais variáveis independentes você escolheu para o modelo e por quê?

Foram utilizadas métricas de engajamento e características dos vídeos, pois demonstraram potencial preditivo para distinguir claims de opinions.

- Quão bem o seu modelo se ajusta aos dados? Qual é a pontuação de validação do meu modelo?

O modelo apresentou excelente desempenho, com recall próximo de 99% e alta precisão durante a validação.

- Você pode melhorá-lo? Há algo que você mudaria no modelo?

Sim. Poderiam ser testados novos hiperparâmetros e incorporadas novas variáveis relacionadas ao histórico dos criadores e ao comportamento dos usuários.

- Quais recursos você costuma usar para concluir esta etapa?

Scikit-learn, XGBoost, Pandas, NumPy e ferramentas de validação cruzada como GridSearchCV.



PACE: Executar Etapa

- Quais foram as principais conclusões que surgiram do(s) seu(s) modelo(s)? Você pode explicar o meu modelo?

As métricas de engajamento foram os fatores mais importantes para as previsões. O modelo aprende padrões presentes nos dados para classificar automaticamente os vídeos como *claim* ou *opinion*.

- Quais são os critérios para a seleção do modelo?

Recall, precisão, F1-score, acurácia e capacidade de generalização para novos dados.

- Meu modelo faz sentido? Meus resultados finais são aceitáveis?

Sim. Os resultados são consistentes e apresentaram aproximadamente 99% de acurácia, precisão e recall.

- Você acha que seu modelo poderia ser melhorado? Por quê? Como?

Sim. A inclusão de novas variáveis e o ajuste adicional de hiperparâmetros podem aumentar ainda mais o desempenho.

- Havia alguma funcionalidade que não era importante? E se você a removesse?

Algumas variáveis tiveram baixa importância. Sua remoção provavelmente teria pouco impacto no desempenho do modelo.

- Com base nos modelos construídos, que recomendações de negócios/organizacionais você propõe?

Utilizar o modelo para auxiliar a identificação de conteúdos potencialmente classificados como claim, apoiando processos de moderação e priorização de revisões.

- Considerando o seu conhecimento sobre os dados e os modelos que vocês estavam utilizando, que outras perguntas você poderia abordar para a equipe?

Quais fatores influenciam a viralização de conteúdos? Quais características aumentam a probabilidade de um vídeo ser classificado como claim?

- Quais recursos você costuma usar para concluir esta etapa?

Pandas, Scikit-learn, XGBoost, Matplotlib, Seaborn e documentação técnica.

- Meu modelo é ético?

Em geral, sim. No entanto, é importante monitorar possíveis vieses e avaliar continuamente o impacto de erros de classificação nos usuários e criadores de conteúdo.

- Quando meu modelo comete um erro, o que acontece? Como isso se traduz no meu caso de uso?

Um falso positivo pode classificar incorretamente uma opinião como reivindicação. Um falso negativo pode deixar de identificar um conteúdo que deveria ser classificado como reivindicação. Por isso, os resultados do modelo devem servir como apoio à tomada de decisão e não como única fonte de avaliação.