

TikTok Claims Classification Project

Inspeção Inicial de Dados e Preparação para Análise

Project Overview


O time de dados do TikTok visa criar um modelo de machine learning para classificar vídeos automaticamente entre alegações (claims) e opiniões. Inicialmente, o dataset foi organizado para viabilizar a Análise Exploratória de Dados (EDA) e as etapas subsequentes de modelagem.

Key Insights

Vídeos classificados como "claims" possuem alcance exponencialmente maior que "opinions", com medianas significativamente superiores em visualizações (501.555 vs. 4.953), curtidas (123.649 vs. 823) e compartilhamentos (17.997 vs. 121).

Adicionalmente, 88% dos autores banidos publicavam claims; esses vídeos, assim como os de autores sob análise, viralizam muito mais que os de autores ativos, evidenciando a rápida propagação da desinformação antes da moderação.

Total de Claims vs. Opinions



Details

O conjunto possui 19.382 registros brutos e 12 variáveis, 19.084 estão completos. As 298 ausências concentram-se simultaneamente na variável-alvo, no texto do vídeo e no engajamento. A variável-alvo (*claim_status*) está dividida de forma equilibrada nos dados válidos:

```
data['claim_status'].value_counts()

claim      9608
opinion    9476
Name: claim_status, dtype: int64
```

Para investigar o comportamento de cada classe, cruzamos os metadados dos autores (status de banimento e verificação) com métricas de volume absoluto (visualizações, curtidas, compartilhamentos e comentários) e taxas de engajamento relativo por visualização.

Next Steps

- Tratar valores nulos no conjunto de dados.
- Iniciar a Análise Exploratória de Dados (EDA) visual para mapear distribuições gráficas.
- Desenvolver a engenharia de atributos focando em processamento de texto (NLP na transcrição) combinado aos dados de engajamento.